

Introduction à l'Intelligence Artificielle

Stephane CHOLET @ Softbridge Technology 2024
scholet.pro+l3maths@proton.me

version 2 – mars 2024

Plan du cours

- Topic 0 : ce qu'il faut attendre des séances à venir
- Topic 1 : à quel moment peut-on dire d'un système qu'il est intelligent ?
- Topic 2 : la notion d'apprentissage
- Topic 3 : les données
- Topic 4 : les algorithmes
- Topic 5 : éthique et intelligence artificielle

Qu'attendre de ce cours ?

Topic 0

Stephane CHOLET

Responsable recherche
& Data scientist
@SoftbridgeTechnology

- 2010-2019 : LMD @Université des Antilles
Thèse : IA, data, affective computing
- 2019-2020 : @Université de Strasbourg
Deep learning, 3D modeling
- 2020 - : @Softbridge Technology
Process Mining

Au programme

- Une approche davantage industrielle qu'académique
- Un peu d'informatique, juste un peu
- Quid de l'aspect mathématique ?

Organisation

- 8 * 2h de CM pour se familiariser avec les notions clefs
- Un exercice noté au dernier CM
- 6 * 2h de TD/TP pour (re)découvrir Python et mettre les mains dans le cambouis
- Un TP noté à la dernière séance de TD
- Un CC après la dernière séance de CM

A quel moment un système est-il intelligent ?

Topic 1

On souhaite mettre au point un système capable de prédire la face du prochain lancer de dé.

- De quelles données a-t-on besoin ?
- Comment dire si le système mis au point « fonctionne » ?



A quel moment un système est-il intelligent ?

Topic 1

On souhaite mettre au point un système capable de prédire la face du prochain lancer de dé.




- De quelles données a-t-on besoin ?
- Comment dire si le système mis au point « fonctionne » ?

Un système sera considéré comme étant intelligent s'il est capable **d'apprendre**, de **raisonner** et de **résoudre** un problème. Toutefois, cette définition souffre du même mal que les autres tentatives : elle est vague et ne suffit pas toujours.

La notion d'apprentissage

Topic 2

Machine Learning : concepts permettant à un système d'apprendre à prédire une information à partir d'observations



Nomenclature des techniques d'apprentissage

Topic 2

- Catégorisation selon la disponibilité de l'information à prédire
 - Apprentissage supervisé, si l'information est disponible
 - Apprentissage non supervisé, si l'information n'est pas disponible
 - Apprentissage par renforcement,
- Ou bien selon le type de l'information à prédire :
 - Classification, si l'information à prédire est une classe
 - Régression, si l'information à prédire est une valeur (continue)

Focus : la classification

Topic 2

[n. f] Processus qui consiste à associer automatiquement une catégorie à un élément.

On désigne par classification le processus qui consiste à associer automatiquement une catégorie à un élément. Par opposition, la régression consiste à associer automatiquement une valeur réelle à un élément. Une observation, appelé exemple ou motif, est représenté par un vecteur $\mathbf{x} = (x_1, \dots, x_m)$ de dimension m . Un ensemble de n exemples $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ est appelé jeu (ou base) de données. En classification, une catégorie, appelée classe, est représentée par une valeur discrète $y \in \{k_1, \dots, k_c\}$ où c est le nombre de classes possibles.

Focus : la classification

Topic 2

[n. f] Processus qui consiste à associer automatiquement une catégorie à un élément.

L'apprentissage est supervisé quand la classe de chaque exemple est connue d'avance. On note $S = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$ un ensemble de données annotées. L'objectif est alors d'entraîner un modèle de classifieur en apprenant sur les données afin de trouver une fonction $f : \mathbf{x} \in \mathbb{R}^m \mapsto y' \in \{k_1, \dots, k_c\}$ qui associe à un exemple \mathbf{x} une classe calculée y' . Si la classe (ou sortie) calculée y' est égale à la classe y de l'élément (sortie désirée), alors l'exemple est dit bien classé. Dans le cas contraire, il est dit mal classé. Des mesures de performance existent et permettent d'évaluer la capacité d'un classifieur à reconnaître un motif connu (performances en apprentissage) ou inconnu (performances en généralisation).

Exemples de classifieurs

Topic 2

k-NN : à fréquenter des chiens on attrape des puces

L'idée fondamentale derrière les k-NN (k plus proches voisins) est qu'un exemple, dans son espace de représentation et sous couvert du choix d'une mesure de distance adaptée, **sera similaire à ses k plus proches voisins**, dont il partagera par conséquent la classe.

Question : pensez-vous qu'un tel algorithme puisse être « efficace » ?



Dans la série « Nos chers voisins », chaque foyer incarne un stéréotype : les coloc ratés, la chaudasse, le couple coinços, la famille recomposée et le vieux solitaire. Une hérésie que l'algorithme des k-NN n'aurait pas permis !

sortage
TECHNOLOGY

Exemples de classifieurs

Topic 2

Procédure de classification pour les k-NN

L'algorithme nécessite de choisir un nombre k , représentant le nombre de voisins qui seront analysés pour chaque exemple. On calcule ensuite la distance entre l'exemple courant et tous les autres. Les k voisins retenus sont ceux dont la distance est la plus faible. On procède alors à un vote majoritaire, et la classe la plus représentée parmi les k voisins est attribuée à l'exemple courant.

Exercice : formalisez cette description en utilisant une notation algorithmique

Exemples de classifieurs

Topic 2

Algorithme pour les k-NN

Exemples de classifieurs

Topic 2

Stop le 20 mars 2023

Algorithme pour les k-NN

Initialiser le nombre de voisins k

Pour chaque exemple $\mathbf{x} \in \mathbf{X}$

 Pour chaque exemple $\mathbf{x}' \in \mathbf{X}$

 calculer $dist(\mathbf{x}, \mathbf{x}')$

 Parmi les k \mathbf{x}' plus proches de \mathbf{x}

 Déterminer le label y le plus répandu

 Attribuer à \mathbf{x} le label y

Exemples de classifieurs

Topic 2

Question : à quelle classe appartiendrait le point incolore pour différentes valeurs de k ?



Exemples de classifieurs

Topic 2

Visualisation des k -NN en action



Exemples de classifieurs

Topic 2

kMeans : qui se ressemble s'assemble

L'objectif du kMeans, qui est aussi celui de tous les algorithmes de classification non supervisée, est de créer **des groupes d'individus homogènes**, c'est-à-dire qui se ressemblent. De manière sous-jacente, l'algorithme kMeans va chercher à former des groupes, appelés clusters, tel que la similarité entre les individus d'un même groupe soit maximale.

Question : Quelle différence majeure peut-on noter par rapport aux k-NN ?

Exemples de classifieurs

Topic 2

Procédure de classification pour les kMeans

On commence par choisir un nombre k , représentant le nombre de clusters à trouver. On initialise k barycentres dans l'espace des données, chacun correspondant à un cluster. Chaque individu est associé au cluster dont il est le plus proche. Une fois que tous les individus ont été assignés à un cluster, on recalcule le barycentre du cluster comme étant la moyenne des individus assignés au cluster. On procède alors à une nouvelle passe d'association entre chaque individu et un cluster, avec cette fois les nouveaux barycentres comme références. Une fois que les assignations n'évoluent plus, on arrête l'algorithme.

Exercice : formalisez cette description en utilisant une notation algorithmique.

Exemples de classifieurs

Topic 2

Algorithme de classification pour les kMeans

Exemples de classifieurs

Topic 2

Algorithme de classification pour les kMeans

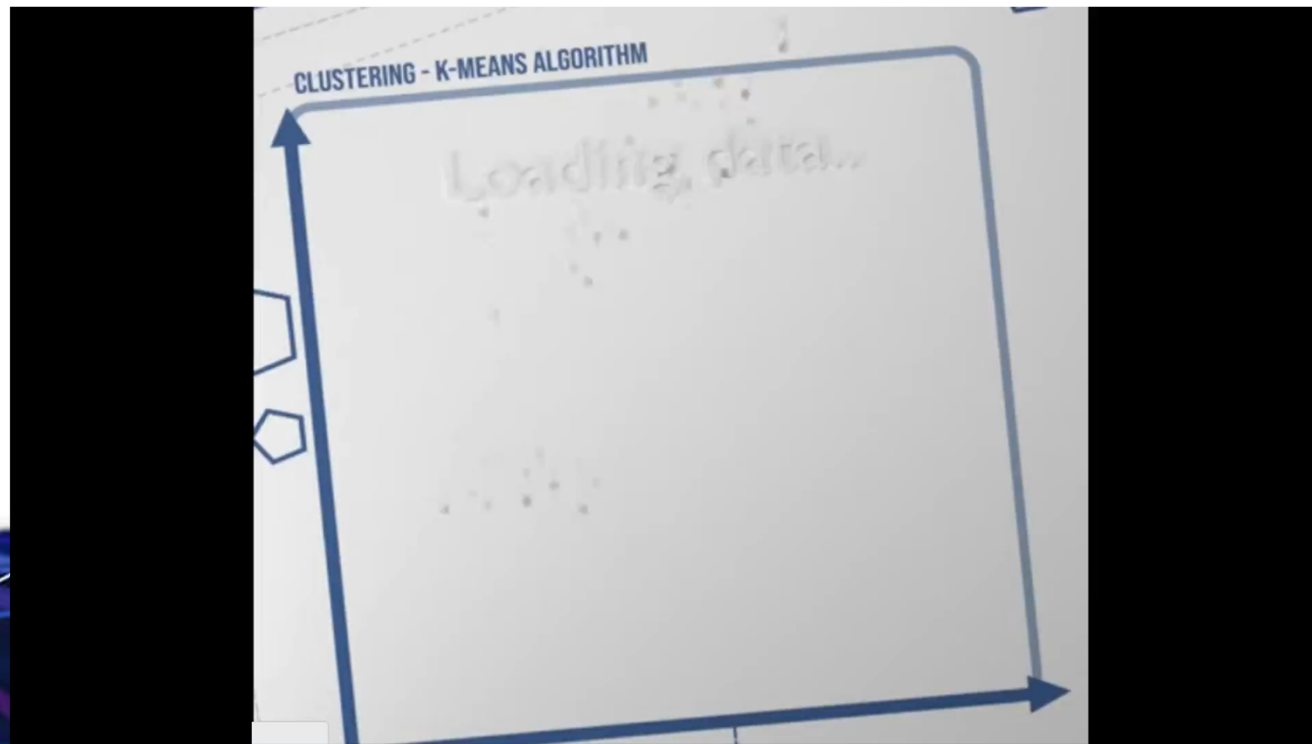
K-means (D, k, ϵ):

- 1 $t = 0$
- 2 Randomly initialize k centroids: $\mu_1^t, \mu_2^t, \dots, \mu_k^t \in \mathbb{R}^d$
- 3 **repeat**
- 4 $t \leftarrow t + 1$
- 5 $C_j \leftarrow \emptyset$ for all $j = 1, \dots, k$
 // Cluster Assignment Step
- 6 **foreach** $x_j \in D$ **do**
- 7 $j^* \leftarrow \arg \min_i \{ \|x_j - \mu_i^t\|^2 \}$ // Assign x_j to closest
 centroid
- 8 $C_{j^*} \leftarrow C_{j^*} \cup \{x_j\}$
- 9 // Centroid Update Step
- 10 **foreach** $i = 1$ to k **do**
- 11 $\mu_i^t \leftarrow \frac{1}{|C_i|} \sum_{x_j \in C_i} x_j$
- 11 **until** $\sum_{i=1}^k \|\mu_i^t - \mu_i^{t-1}\|^2 \leq \epsilon$

Exemples de classifieurs

Topic 2

Visualisation des kMeans en action



Evaluation

Topic 2

- D'un point de vue académique, on doit :
 - L'apprentissage
 - La généralisation
- Dans l'industrie, il faut aussi évaluer :
 - Le passage à l'échelle
 - Les ressources nécessaires (temps, électricité, matériel, RH)
 - Le gain de valeur (« cela vaut-il le coût d'utiliser cet algorithme ? »)

Exemple : Les iris

Topic 2

Vérité	Prédiction		Espèce	Nombre	
virginica	versicolor		versicolor	?	
versicolor	versicolor		virginica	?	
versicolor	versicolor		setosa	?	
versicolor	versicolor				
versicolor	versicolor		tx succès	?	<i>accuracy, success rate</i>
versicolor	versicolor		precision	?	
versicolor	versicolor		rappel	?	<i>recall, true positive rate (TPR), sensitivity</i>
versicolor	versicolor		specificite	?	<i>specificity</i>
versicolor	versicolor		FPR	?	<i>false positive rate</i>
versicolor	versicolor		FNR	?	<i>false negative rate</i>
versicolor	versicolor				
setosa	versicolor		VP	?	<i>classé versicolor et il est bien versicolor</i>
versicolor	versicolor		VN	?	<i>pas classé versicolor alors qu'il n'est pas versicolor</i>
setosa	versicolor		FP	?	<i>classé versicolor alors qu'il n'est pas versicolor</i>
versicolor	versicolor		FN	?	<i>pas classé versicolor alors qu'il est versicolor</i>

iris setosa



petal sepal

iris versicolor



petal sepal

iris virginica



petal sepal


Mesures de performance

Topic 2

- Matrice de confusion

- Vrais positifs (VP)
- Vrais négatifs (VN)
- Faux positifs (FP)
- Faux négatifs (FN)

Model label	Reality
Pregnant	Pregnant
Pregnant	Not pregnant
Pregnant	Pregnant
Pregnant	Not pregnant
Pregnant	Pregnant
Pregnant	Not pregnant
Not pregnant	Not pregnant



		Reality	
		0 Not pregnant	1 Pregnant
Prediction	0 Not pregnant	?	?
	1 Pregnant	?	?

Mesures de performance

Topic 2

- Matrice de confusion

- Vrais positifs (VP)
- Vrais négatifs (VN)
- Faux positifs (FP)
- Faux négatifs (FN)

Model label	Reality
Pregnant	Pregnant
Pregnant	Not pregnant
Pregnant	Pregnant
Pregnant	Not pregnant
Pregnant	Pregnant
Pregnant	Not pregnant
Not pregnant	Not pregnant

Confusion matrix

		Reality	
		0 Not pregnant	1 Pregnant
Prediction	0 Not pregnant	TN = 1	FN = 0
	1 Pregnant	FP = 3 ▲	TP = 3

Mesures de performance

Topic 2

- *Accuracy*
 - Taux d'exemples bien classés
- *Precision*
 - Taux de prédictions positives correctes

$$\text{Acc} = \frac{VP + VN}{VP + VN + FP + FN}$$

$$\text{Précision} = \frac{VP}{VP + FP}$$

Ensemble, ces deux indicateurs donnent une première interprétation du comportement du classifieur. Par exemple, un taux de succès élevé est synonyme d'une bonne classification. Toutefois, s'il est accompagné d'une précision faible, cela signifie que les exemples de la classe considérée sont peu nombreux (le classifieur aura d'avantage reconnu les exemples n'appartenant pas à la classe).

Mesures de performance

Topic 2

- *Sensitivity, recall, TPR (true positive rate)*
 - *Taux de vrais positifs*
- *Specificity*
 - *Taux de vrais négatifs*

$$\text{Rappel} = \frac{VP}{VP + FN}$$
$$\text{Specificite} = \frac{VN}{VN + FP}$$

La sensibilité ou rappel (*sensitivity* ou *recall*), et la spécificité (*specificity*) fournissent une interprétation plus fine. Le rappel estime le nombre d'éléments appartenant à une classe et qui y ont été assignés, alors que la spécificité estime le nombre d'éléments n'appartenant pas à une classe et qui n'y ont pas été assignés.

Mesures de performance

Topic 2

Machine learning \ Manual counting	True	False
True	True Positive (TP)	False Positive (FP)
False	False Negative (FN)	True Negative (TN)

Equations:

$$\text{False positive rate (FPR)} = \frac{FP}{FP+TN}$$

$$\text{False negative rate (FNR)} = \frac{FN}{FN+TP}$$

$$\text{Sensitivity} = \frac{TP}{TP+FN}$$

$$\text{Specificity} = \frac{TN}{TN+FP}$$

$$\text{Youden index} = \text{Sensitivity} + \text{Specificity} - 1$$

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

Mesures d'erreur

Topic 2

- Erreur moyenne quadratique
 - *Mean Squared Error*
- Racine carrée de l'err. moy. quad.
 - *Root mean squared error*

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^n (\mathbf{y} - \mathbf{y}')^2$$
$$\text{RMSE} = \sqrt{\text{MSE}}$$

Si ces deux mesures sont conceptuellement très proches, la RMSE accorde la même importance à tous les écarts, alors que la MSE donne plus d'importance aux grands écarts. Les deux mesures sont définies dans \mathbb{R}^+ et sont à l'échelle des variables mesurées. Les valeurs proches de 0 indiquent une erreur faible, i.e. une bonne performance.

Mesures de corrélation

Topic 2

- Pearson
- *Lin, concordance correlation coefficient*
- Spearman




FIGURE 2.9 – Interprétation du coefficient de Pearson

$$\rho = \frac{cov(\mathbf{y}, \mathbf{y}')}{\sigma_{\mathbf{y}} \sigma_{\mathbf{y}'}}$$

$$CCC = \frac{2\rho\sigma_{\mathbf{y}}\sigma_{\mathbf{y}'}}{\sigma_{\mathbf{y}}^2 + \sigma_{\mathbf{y}'}^2 + (\mu_{\mathbf{y}} - \mu_{\mathbf{y}'})^2}$$

$$\rho_S = \frac{\sum_{i=1}^n (y_i - \mu_y)(y'_i - \mu_{y'})}{\sqrt{\sum_{i=1}^n (y_i - \mu_y)^2 \sum_{i=1}^n (y'_i - \mu_{y'})^2}}$$

μ	Moyenne
σ	Ecart-type
σ^2	Variance
cov	Covariance
ρ	Coefficient de corrélation linéaire de Pearson
ρ_S	Coefficient de corrélation linéaire de Spearman
CCC	Coefficient de concordance des corrélations

Pourquoi tant de types de mesures ?

Topic 2

Matrice de confusion

Représentation synthétique,
dans l'idéal il faut que ce soit
une matrice diagonale

Mesures de performance

Pertinentes lorsqu'on souhaite
évaluer la capacité d'un
classifieur à prédire exactement
la classe d'un exemple.

Mesures d'erreur ou de corrélation

Pertinentes lorsqu'on veut évaluer
la capacité d'un classifieur à prédire
une classe proche de celle de
l'exemple en entrée



Mesures de corrélation

Pertinentes lorsqu'on évalue des
régresseurs, bien que des usages
existent en classification

Bonus : la courbe ROC


Topic 2

Un classifieur produit en réalité « une probabilité d'appartenance » à une classe, qui est seuillée au moyen d'un seuil (*threshold*) pour déterminer l'appartenance à ladite classe. Ce seuil est appelé le « *cut-off* » (en abscisse). On peut faire bouger ce seuil pour arriver à un bon compromis entre spécificité et sensibilité.



Bonus : la courbe ROC


Topic 2



<u>AUC</u>	<u>Quality of Test</u>
0.9-1	Excellent
0.8-0.9	Good
0.7-0.8	Fair
0.6-0.7	Poor
0.5-0.6	Fail

Overfitting, underfitting, biais et variance

Topic 2



Les données

Topic 3

Iris dataset, again ...

1	sepal length	sepal width	petal length	petal width	target
2	5.1	3.5	1.4	0.2	Iris-setosa
3	4.9	3.0	1.4	0.2	Iris-setosa
4	4.7	3.2	1.3	0.2	Iris-setosa
5	4.6	3.1	1.5	0.2	Iris-setosa
6	5.0	3.6	1.4	0.2	Iris-setosa
7	5.4	3.9	1.7	0.4	Iris-setosa
8	4.6	3.4	1.4	0.3	Iris-setosa
9	5.0	3.4	1.5	0.2	Iris-setosa
10	4.4	2.9	1.4	0.2	Iris-setosa
11	4.9	3.1	1.5	0.1	Iris-setosa
12	5.4	3.7	1.5	0.2	Iris-setosa
13	4.8	3.4	1.6	0.2	Iris-setosa
14	4.8	3.0	1.4	0.1	Iris-setosa

Notions (en anglais):

- Data
- Example, observation, exemplar
- Sample
- Label, annotation, target, expected output
- Feature
- Descriptor
- Variable, column
- Dimension
- Class balancing
- Variable correlation
- ...

Notations courantes

Topic 3

Symbole	Signification
m	Dimension d'un vecteur ou nombre de colonnes d'une matrice
n	Nombre de vecteurs ou nombre de lignes d'une matrice
i	Utilisé pour l'indexation d'un vecteur ou des lignes d'une matrice
j	Utilisé pour l'indexation des colonnes d'une matrice
c	Nombre de classes
k	Nom d'une classe
\mathbf{x}	Vecteur de données, avec $\mathbf{x} = (x_1, \dots, x_m)$ et $\forall i \in \{1, \dots, m\}, x_i \in \mathbb{R}$
\mathbf{X}	Matrice des données, avec $\mathbf{X} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ et $\forall j \in \{1, \dots, n\}, \mathbf{x}_j \in \mathbb{R}^m$
\mathbf{y}	Vecteur d'annotations, avec $\mathbf{y} = (y_1, \dots, y_n)$ et $y = \{k_1, \dots, k_c\}$
S	Ensemble de données, tel que $S = \{(\mathbf{x}_1, \mathbf{y}_1), \dots, (\mathbf{x}_n, \mathbf{y}_n)\}$
\mathbf{x}^\top	Transposée d'un vecteur

Préparation des données

Topic 3

Préparer les données : une étape cruciale et fastidieuse

Data cleaning
Normalization
Standardization

Feature selection
Dimension reduction
Variable encoding
Outliers removal

Data cleaning

Topic 4

- **Imputation** : fournir une valeur en lieu et place de la valeur manquante
- **Omission** : retirer l'exemple qui contient une valeur manquante
- **Analyse** : ne pas apporter de solution aux valeurs manquantes

1	sepal length	sepal width	petal length	petal width	target
2	5.1	3.5		0.2	Iris-setosa
3	4.9	3.0	1.4	0.2	Iris-setosa
4	4.7	3.2	1.3	0.2	
5	4.6	3.1	1.5	0.2	Iris-setosa
6	5.0	3.6	1.4	0.2	Iris-setosa
7	5.4		1.7	0.4	Iris-setosa
8	4.6	3.4	1.4	0.3	Iris-setosa
9	5.0	3.4	1.5	0.2	Iris-setosa
10	...	2.9	...	0.2	
11	4.9	3.1	1.5	0.1	Iris-setosa
12	5.4	3.7	1.5		Iris-setosa
13	4.8	3.4	1.6	0.2	Iris-setosa
14	4.8	3.0	1.4	0.1	Iris-setosa

Normalisation (min-max scaling)

Topic 3

Pros :

- Chaque variable contribue équitablement en cas de calcul de distance
- Pratique quand les features sont dans des échelles différentes
- Les données sont bornées entre 0 et 1, ou bien dans un intervalle défini

Cons :

- Sensible aux outliers (les retirer avant !)

The diagram illustrates the Min-Max Scaling process. At the top, the words "MIN MAX" are written in large, colorful, hand-drawn letters, followed by "SCALING" in grey block letters. Below this, the text "Rescales feature values to between 0 and 1" is written. An arrow points from this text to the formula for the rescaled value. The formula is:
$$X'_i = \frac{X_i - \min(x)}{\max(x) - \min(x)}$$
 The components of the formula are labeled with handwritten text and arrows: "Original value" points to X_i ; "Minimum value in feature" points to $\min(x)$; "Maximum value in feature" points to $\max(x)$; "Rescaled value" points to X'_i . The signature "Chris Albon" is at the bottom left of the diagram.

MIN MAX
SCALING

Rescales feature values to between 0 and 1

Original value X_i

Minimum value in feature $\min(x)$

Maximum value in feature $\max(x)$

Rescaled value X'_i

Chris Albon

Standardization (Z-score scaling)

Topic 3

Pros :

- Donne à chaque feature une distribution gaussienne (centrée en la moyenne et d'écart-type 1)
- Pratique si on ne connaît pas l'échelle des données, ou bien si elle n'en a pas

Cons :

- Change la distribution des données !

$$x_{\text{stand}} = \frac{x - \text{mean}(x)}{\text{standard deviation}(x)}$$

Feature selection & Dimension reduction

Topic 3

- **Feature selection** : choisir les features que l'on va utiliser.
- **Dimension reduction** : changer la représentation du jeu de données vers un espace de moindre dimension (PCA, t-SNE, ...)

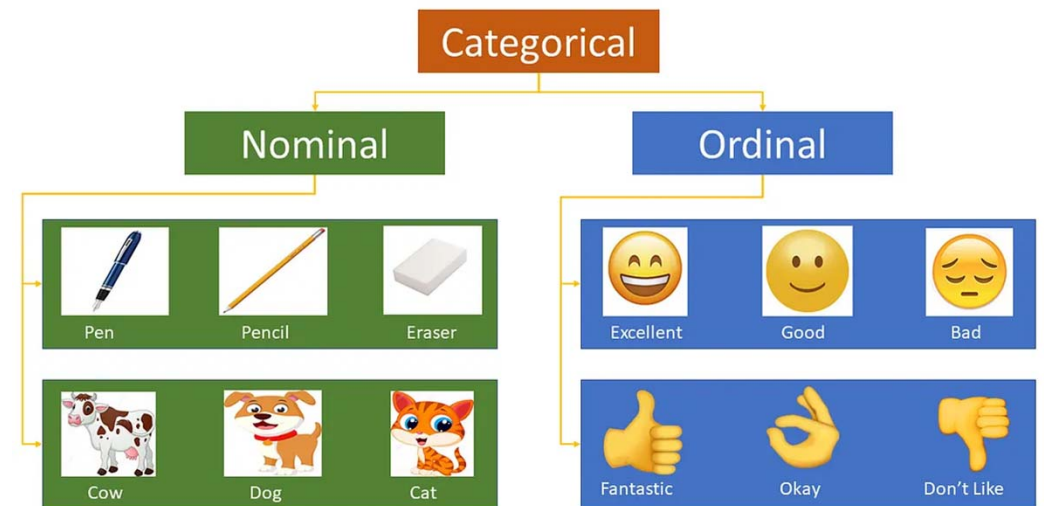
Note : les deux techniques réduisent la dimension des données !

Encodage des variables

Topic 3

Types de variables:

- **Catégoriel**
 - **Nominal** : sans relation d'ordre entre les catégories (mâle/femelle, couleur, etc.)
 - **Ordinal** : il existe une relation d'ordre entre les catégories (degré de satisfaction, échelle de douleur, etc.)
- **Numérique**



Encodage des variables

Topic 3

Exemples d'encodages :

- **One hot encoding**
- **Label encoding**
- **Ordinal encoding**
- **Binary encoding**
- **Frequency encoding**
- ...

Outliers removal

Topic 3

Suppression des données aberrantes

Une **donnée aberrante** est un point dont le comportement s'écarte « trop » du reste des données. On peut les identifier en calculant la distribution ou des distances.

Algoríthmes d'IA

Topic 4

Ethique et IA

Topic 5

L'intelligence artificielle occupe une place grandissante dans la société et dans nos vies. Nous arrivons bientôt à un point où nous sommes à la fois **producteurs de données** pour l'IA, **utilisateurs de résultats** fournis par des IA et enfin, **utilisateurs ou créateurs de systèmes intelligents**.

Cette omniscience soulève des problématiques liées à l'éthique, où l'on peut/doit se demander si l'utilisations que nous faisons de l'IA est « juste » et respectueuse des valeurs humaines qui régissent la morale et la société.

Ethique et IA

Topic 5

Pouvez-vous citer quelques cas où des problèmes liés à l'éthiques découlaient de l'usage d'une IA ?

Ethique et IA

Topic 5

La censure sur les réseaux sociaux :

- où placer la frontière entre censure et modération ?

Contenus Black Lives Matter supprimés de Tiktok (2021)

Contenus Identity Evropa autorisés (Facebook, 2022)

Cas des réseaux sociaux

Topic 5

L'un des objectifs des réseaux sociaux est de faire en sorte que l'utilisateur interagisse avec le maximum de contenus possibles (vues, likes, partages, etc.). Pour ce faire, des contenus similaires à ceux regardés seront systématiquement proposés.

Par effet de bord (désiré ou non), un utilisateur se verra souvent présenter des contenus avec lesquels il est d'accord. Cela crée des communautés de personnes qui partageant des intérêts parfois immoraux, voire illégaux : xénophobie, racisme, drogues, ventes d'armes, etc.

Il y a des conflits d'intérêts latents : monétisation des contenus, promotion d'activités immorales ou illégales, liberté d'expression (par ex., le racisme est-il une opinion ou un danger ?)

Quid de la responsabilité

Topic 5

Si un véhicule autonome fait un accident, qui doit être tenu fautif ?

Quid de la responsabilité

Topic 5

Si on entraîne une IA avec des photos de criminels pour qu'elle prédise les chances pour qu'un individu commette un crime ; et qu'on réalise que la plupart de ses prédictions positives sont faites sur des individus noirs, peut-on accuser le système (ou ses utilisateurs) de racisme ?

Quid de la responsabilité

Topic 5

Cas de Prépol : l'usage de systèmes intelligents visant à répartir les ressources de police tendent à les allouer dans des zones défavorisées. Peut-on accuser le système ou ses utilisateurs de discrimination ?

Opposition entre le bien et le mal

Topic 5

Certains systèmes intelligents sont déjà capables de remplacer un humain dans certaines tâches, parfois dans des tâches intellectuelles complexes comme la gestion des emplois du temps ou l'enseignement.

Est-ce bien ?

Opposition entre le bien et le mal

Topic 5

Les assureurs calculent les primes que paieront leurs clients en se basant notamment sur des profils types et l'historique des assurés. Aussi, dans la mesure où les hommes sont plus d'accidents que les femmes, une IA pourrait proposer de faire payer davantage aux hommes.

Est-ce mal ?

Les grands enjeux de l'éthique et de l'IA

Topic 5

- Équité
- Transparence
- Explicabilité
- Responsabilité
- Respect de la vie privée
- Sécurité des biens et des personnes

Fin
